

模型结果汇报与亮点——魏旎

- 结果汇报
- 模型亮点
 - 数据提取
 - 运用正则表达式匹配、字符串匹配、字典映射,完成数据提取和汉字转换
 - Sales房屋优势、Rent配套设施等列具有自然语言特征,对关键词编码
 - 特征工程
 - 独热编码: 对分类型变量、无序数特征(城市/区域/板块)的变量进行独热编码
 - 引入交互项: 楼层比、套内面积比、梯户比、楼房比、绿化容积比
 - 缺失值处理
 - 删除缺失值过多的特征和样本
 - 数值型特征: InterativeImputer迭代填充
 - 分类型特征: 基于数值型特征KNN, 在最相近的K个样本中取众数
 - 异常值发现与处理: 3σ原则,删除异常样本(Sales: 88688 Rent: 84358)
 - 目标变量转化: Price -> Price/Area

| Metrics | Туре | In sample | Out of sample | Cross validatio n | Kaggle |
|----------------------|-------|--------------|---------------|-------------------------|--------|
| OLS | Sales | 0.199 | 0.2011 | 0.1998 | 61.51 |
| | Rent | 0.2283 | 0.2278 | 0.2289 | |
| Lasso | Sales | 0.1988 | 0.2006 | 0.1996 | 61.96 |
| | Rent | 0.2282 | 0.2277 | 0.2288 | |
| Ridge | Sales | 0.1984 | 0.2004 | 0.1992 | 61.79 |
| | Rent | 0.2283 | 0.2278 | 0.2289 | |
| ElasticNet | Sales | 0.1991 | 0.2008 | 0.1999 | 61.64 |
| | Rent | 0.2283 | 0.2277 | 0.2289 | |
| Average | Sales | - | - | - | 61.89 |
| | Rent | | | | |
| Best linear model | Sales | 0.1984 | 0.2004 | 0.1992 | 61.79 |
| | Rent | 0.2283 | 0.2278 | 0.2289 | |